

Recomendación de variables manipulables en molinos SAG con Reinforcement Learning Offline

Propuesta de proyecto final

Nombre: José Luis Cádiz.

Curso: Seminario de robótica y sistemas autónomos - EL7021 otoño 2023.

Profesor: Javier Ruiz del Solar.

1. Motivación:

En el contexto de la digitalización de la industria minera, es usual el desarrollo de aplicaciones web para visualizar información útil con el objetivo de facilitar la toma de decisiones en la operación de maquinaria. Existe un foco particular, consistente en brindar recomendaciones de como operar variables manipulables para optimizar funciones objetivo como costos o producción.

La decisión de tomar una u otra decisión sobre variables manipulables depende del contexto operacional y la decisión que se tome en el corto plazo puede que mejore resultados en el corto plazo, pero los empeore en el largo plazo, es por esto que se propone modelar este tipo de problemas como un proceso de decisión de Markov (MDP) con el objetivo obtener políticas óptimas que consideren los resultados tanto en el corto plazo como en el largo plazo utilizando Reinforcement Learning (RL).

En la industria minera, se utiliza maquinaria de alta inversión. Debido a esto, la experimentación en tiempo real para mejorar la toma de decisiones no es posible. Por lo tanto, el enfoque típico de RL que interactúa con el entorno no es factible. Sin embargo, existe un nuevo enfoque de RL llamado RL Offline [1][2], que se caracteriza por aprender políticas óptimas únicamente a partir de datos históricos.

Un ejemplo de aplicación de RL Offline para optimizar procesos industriales se puede encontrar en el paper “DeepThermal: Combustion Optimization for Thermal Power Generating Units Using Offline Reinforcement Learning” [3].

Una problemática particular se encuentra en molinos SAG, los cuales, si no son operados correctamente, pueden convertirse en un cuello de botella para toda la cadena de producción de cobre.

Por lo mencionado anteriormente, se propone como proyecto modelar al menos 1 de 2 de potenciales problemas asociados a molinos SAG. A continuación, se detalla cada uno de ellos:

1. **Estabilización de TPH mediante recomendación de su nivel de carga:** Este problema consiste en definir el setpoint de su nivel de carga con el objetivo de que no se generen pérdidas de TPH (toneladas por hora). El setpoint del nivel de carga se establece acorde al contexto operacional en el que se encuentra el molino, el cual está definido principalmente por su granulometría, propiedades mineralógicas, porcentaje de sólidos, rpm entre otros.
2. **Reducción de cuellos de botella por alto nivel de arcilla mediante recomendación de rpm y porcentaje de sólidos:** Este problema consiste en definir valores óptimos de rpm y porcentaje de sólidos para evitar fenómenos de atollo en escenarios de alto nivel de arcilla. Las variables que definen el contexto de este fenómeno son: pebbles recirculados, tph, rpm, nivel de arcillas entre otros.

2. Objetivos:

- I. **Objetivo general:** Demostrar un aprendizaje de políticas óptimas utilizando Reinforcement Learning Offline mediante la modelación de fenómenos de interés en molinos SAG como un proceso de toma de decisión de Markov.
- II. **Objetivos específicos:**
 - i. Definir función de recompensa acorde a las necesidades del problema.
 - ii. Modelar el proceso mediante tuplas de la forma $(s_t, a_t, r_t, s_{t+1}, done_t)$.
 - iii. Aprender a utilizar la librería d3rlpy [4] para facilitar el uso de algoritmos de Reinforcement Learning Offline.
 - iv. Demostrar que existe un aprendizaje de políticas óptimas.

3. Entregable:

- I. Modelo entrenado que sea capaz de entregar políticas óptimas acorde al contexto del problema.
- II. Visualización de gráficos que evidencien la mejora del reward acumulado luego de concluir el proceso de aprendizaje.

4. Planificación:

Hito/semana	26/07	03/07	10/07	17/07
Entrega de propuesta				
Definición de función de recompensa				
Modelamiento MDP				
Aprendizaje de librería d3rlpy				
Generación de experimentos				
Entrega final				

5. Referencias:

- [1] Levine, S., Kumar, A., Tucker, G., & Fu, J. (2020). Offline reinforcement learning: Tutorial, review, and perspectives on open problems.
- [2] Agarwal, R., Schuurmans, D., & Norouzi, M. (2020, November). An optimistic perspective on offline reinforcement learning. In International Conference on Machine Learning.
- [3] Zhan, X., Xu, H., Zhang, Y., Zhu, X., Yin, H., & Zheng, Y. (2022, June). Deepthermal: Combustion optimization for thermal power generating units using offline reinforcement learning. In Proceedings of the AAAI Conference on Artificial Intelligence.
- [4] Seno, T., & Imai, M. (2022). d3rlpy: An offline deep reinforcement learning library. The Journal of Machine Learning Research.